




Creación de un modelo de Machine Learning
para la detección y prevención de incendios
forestales



Problema de negocio




Problema de negocio



Problema de negocio: ¿Por qué un modelo de ML?

- La prevención de incendios se apoya hoy en índices agregados (FWI) y experiencia de campo, sin un modelo que combine sistemáticamente las variables disponibles
- El modelo ayuda a decidir dónde priorizar la vigilancia y los recursos de prevención
- Coste asimétrico de los errores: un incendio no detectado (falso negativo) es mucho más grave que una falsa alerta (falso positivo)



Planteamiento técnico



Planteamiento técnico

- Clasificación binaria: ¿se produce un incendio (1) o no (0)?
- Hipótesis: las variables meteorológicas de corto plazo junto al FWI son suficientes para discriminar entre casos verdaderos de incendio y “falsas alarmas”
- Criterios de éxito fijados de antemano: recall clase positiva $\geq 70\%$, recall clase negativa $> 50\%$
- Por qué no el 100%: límite inherente del problema (causas antrópicas no capturadas por los datos) y trade-off observado empíricamente entre ambas clases

Dataset y EDA

The background of the slide is a stylized illustration of a wildfire. In the foreground, there are dark brown silhouettes of trees and bright orange and yellow flames. A thick layer of grey smoke fills the middle ground. In the background, there are brown, jagged mountain peaks under a light pink sky. A few small black birds are flying in the sky.




Dataset y EDA

Variable	Tipo de dato	Nº nulos	% nulos	Nº valores únicos	Descripción
daynight_N	float64	0	0.0	2	0 = noche, 1 = día
lat	float64	0	0.0	117561	
lon	float64	0	0.0	118094	
fire_weather_index	float64	0	0.0	115108	
pressure_mean	float64	0	0.0	48551	
wind_direction_mean	float64	0	0.0	7612	
wind_direction_std	float64	0	0.0	98239	Desviación estándar de la dirección del viento (1h)
solar_radiation_mean	float64	0	0.0	6240	
dewpoint_mean	float64	0	0.0	14199	
cloud_cover_mean	float64	0	0.0	2401	
evapotranspiration_total	float64	0	0.0	2334	Evapotranspiración total (1h)
humidity_min	float64	0	0.0	89	Humedad mínima (1h)
temp_mean	float64	0	0.0	11114	
temp_range	float64	0	0.0	616	
wind_speed_max	float64	0	0.0	433	Velocidad máxima del viento (1h)
occured	float64	0	0.0	2	Target: 1 = incendio detectado, 0 = no detectado
frp	float64	0	0.0	10911	Fire Radiative Power (para regresión, no usada aquí)

<https://www.kaggle.com/datasets/vijayaragulvr/wildfire-prediction/data>


Dataset y EDA

Distribución y outliers por variable (X_train)



- Outliers presentes en la mayoría de las features.
- Tratamiento con PowerTransformer (estandarización y transformación por Yeo-Johnson).
- Target equilibrado
- Desequilibrio en el número de casos de 'daynight_N'.

Dataset y EDA




- Variables de 'humidity_mean' y 'evapotranspiration_total' presentaron una fuerte correlación con otras variables.
- Feature 'frp' no es de utilidad para este problema de clasificación (se elimina).
- FWI basado en variables medioambientales contenidas en la tabla: limitación para feature engineering.

Modelado y resultados




Modelado y resultados




Modelado y resultados

LightGBM: La base del cambio





Predicción en base al recall



Predicción en base a f1

Modelado y resultados



Conclusiones



Conclusiones



Modelo final suficiente

Detecta 4 de cada 5 incendios aproximadamente



Contraste ensemble vs modelos individuales

Métricas muy similares en todos los casos



Limitaciones y mejoras

Corregir desequilibrios e incluir nuevas variables



Metodología cronológica

Comparativa de datos estacionales

¡Muchas gracias!

